Họ và tên: Đoàn Thảo Vy

MSSV: 24522052

Báo cáo DS201- Lab 3

Tóm tắt

Với cấu hình embedding 300, hidden 256, 5 lớp, seed 42, LSTM đạt macro-F1 0.7800 trên test, hơn hẳn baseline TF-IDF (0.6483), còn GRU gần như tương đương LSTM (0.7767) và BiLSTM đạt entity micro-F1 0.8909 trên bộ dữ liệu PhoNER.

Bài	Mô hình	Kết quả chính trên test	Tham số	Giây/epoch	Epoch tốt nhất (dev)
1	LSTM 5 lớp	macro-F1 0.7800, accuracy 0.9040	3.138.007	5.3	10
2	GRU 5 lớp	macro-F1 0.7767, accuracy 0.9024	2.468.823	4.8	6
3	BiLSTM 5 lớp (NER)	entity micro-F1 0.8909	8.305.297	6.3	9
4a	LSTM 1 lớp	macro-F1 0.7471, accuracy 0.8999	1.032.663	2.1	4
4a	LSTM 2 lớp	macro-F1 0.7433, accuracy 0.8989	1.558.999	2.9	5
4a	LSTM 5 lớp	macro-F1 0.7800, accuracy 0.9040	3.138.007	5.1	10

Mốc	TF-IDF + Logistic Regression	macro-F1 0.6483, accuracy 0.8898			

- Phần chênh giữa LSTM và TF-IDF nằm chủ yếu ở lớp neutral (F1 0.489 so với 0.120), còn accuracy chỉ hơn 0.014.
- LSTM và GRU chênh nhau 0.003 macro-F1, nằm trong mức nhiễu; GRU ít hơn 21% tham số và nhanh hơn khoảng 9% mỗi epoch.
- Ở NER, DATE, PATIENT_ID, AGE, GENDER và LOCATION đạt F1 từ 0.91 đến 0.96; JOB (0.460) và NAME (0.688) yếu nhất.
- Mô hình 5 lớp cho macro-F1 cao hơn 1 và 2 lớp ở Bài 4a, nhưng chỉ với một seed và chủ yếu nhờ lớp neutral, nên chưa đủ để kết luận độ sâu luôn có lợi.

1. Thiết lập chung

Cả bốn bài dùng cùng cấu hình bắt buộc, cùng quy trình chọn checkpoint theo dev và được chạy trên cùng một môi trường.

Thành phần	**Giá trị**
Embedding / hidden / số lớp	300 / 256 / 5 (Bài 4a: 1, 2 và 5 lớp)
Dropout, batch	0.3 (giữa các lớp RNN và trước lớp tuyến tính cuối), 32
Tối ưu	Adam, lr 1e-3, clip_grad_norm_ 1.0
Số epoch, seed	tối đa 10, seed 42
Chọn checkpoint	epoch có F1 dev cao nhất (macro-F1 cho phân loại, entity-F1 strict IOB2 cho NER)
Embedding	học từ đầu, padding_idx = 0, không dùng mô hình pretrained

Môi trường	Tesla T4, Python 3.13.15, PyTorch 2.11.0+cu128

- Tiền xử lý: Văn bản UIT-VSFC được đưa về chữ thường và tách theo khoảng trắng; PhoNER giữ nguyên chữ hoa và dấu câu. Từ điển xây từ train, lấy từ xuất hiện từ 2 lần trở lên; từ lạ đổi thành <unk>. Từ số tham số embedding suy ra từ điển UIT-VSFC có 1.535 mục (460.500 / 300) và từ điển PhoNER có 2.813 mục (843.900 / 300), tính cả <pad> và <unk>.

- Mô hình: Bộ phân loại câu: Embedding, LSTM hoặc GRU 5 lớp dùng pack_padded_sequence với độ dài thật, lấy trạng thái ẩn cuối của lớp trên cùng, Dropout, Linear(256, 3), loss CrossEntropyLoss. Bộ gán nhãn: Embedding, BiLSTM 5 lớp, pad_packed_sequence khôi phục độ dài, Dropout, Linear(512, 21), loss CrossEntropyLoss(ignore_index=-100); đây là BiLSTM thuần, chưa có CRF. Khi chấm NER, dự đoán và nhãn được cắt theo độ dài thật trước khi đổi sang nhãn chuỗi.

- Độ đo và đánh giá: Sử dụng accuracy, precision-macro, recall-macro, F1-macro và F1 từng lớp; do neutral rất ít mẫu nên F1-macro là độ đo chính. NER báo cáo precision, recall, micro-F1 ở mức thực thể bằng seqeval chế độ strict IOB2, không dùng token accuracy. Test chỉ được đánh giá sau khi huấn luyện xong, với checkpoint đã chọn theo dev. Thời gian/epoch là trung bình 10 epoch, có cả epoch 1 (ví dụ Bài 1: 7.0 giây so với khoảng 5.1 giây các epoch sau) vì phải khởi động GPU.

2. Bài 1: LSTM 5 lớp cho phân loại cảm xúc

LSTM đạt macro-F1 0.7800 và accuracy 0.9040 trên test, hơn baseline TF-IDF 0.1317 macro-F1 (0.6483) nhưng lớp neutral vẫn yếu (F1 0.489).

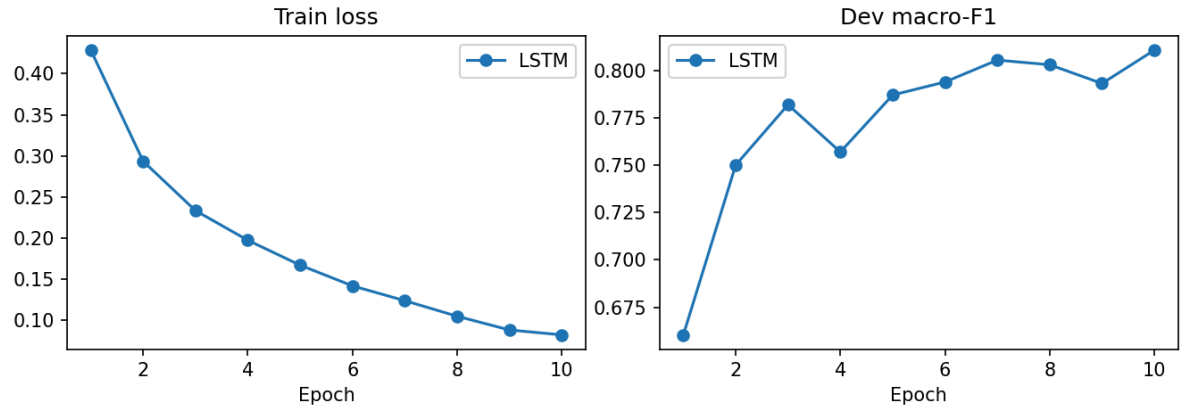
Mô hình	**Tập**	**Accuracy**	**Precision-macro**	**Recall-macro**	**F1-macro**	**F1 negative**	**F1 neutral**	**F1 positive**
LSTM 5 lớp	test	0.9040	0.7883	0.7731	0.7800	0.9228	0.4889	0.9283
TF-IDF + LR	test	0.8898	0.8103	0.6470	0.6483	0.9064	0.1196	0.9190

LSTM 5 lớp	dev	0.9185	0.8029	0.8197	0.8107	0.9366	0.5584	0.9372

LSTM hơn TF-IDF chủ yếu ở recall và lớp neutral: recall-macro 0.7731 so với 0.6470, F1 neutral 0.4889 so với 0.1196. Precision-macro của TF-IDF lại cao hơn (0.8103 so với 0.7883), tức TF-IDF ít khi dự đoán neutral và hiếm khi đoán thì tương đối chắc. Hai lớp lớn (negative, positive) đều đạt F1 trên 0.92 ở LSTM và trên 0.90 ở TF-IDF, nên accuracy chỉ chênh 0.0142.

- Chi phí huấn luyện: **3.138.007 tham số**, trong đó embedding chiếm 460.500 (14,7%) và RNN 2.676.736 (85,3%); trung bình **5.3 giây/epoch** trên Tesla T4; epoch tốt nhất theo dev là **epoch 10** (macro-F1 = 0.8107).

- Đồ thị: Loss train giảm đều từ 0.4286 (epoch 1) xuống 0.0822 (epoch 10). Macro-F1 dev tăng từ 0.6604 lên 0.8107 nhưng không đơn điệu: tụt ở epoch 4 (0.7570) và epoch 9 (0.7932), đỉnh ở epoch 10, cũng là epoch cuối của giới hạn 10 epoch nên chưa thấy điểm bão hòa. Từ dev (0.8107) sang test (0.7800) F1 giảm 0.0307.



Ma trận nhầm lẫn trên test (hàng = nhãn đúng, cột = dự đoán):

Nhãn đúng	negative	neutral	positive
negative (1.409)	1.321	36	52
neutral (167)	42	77	48
positive (1.590)	91	35	1.464

- Phân tích lỗi: Chỉ 77 trong 167 câu neutral được dự đoán đúng (recall 0.461, precision 0.520), còn lại bị đoán sang negative (42) và positive (48), tức mô hình không nghiêng về một phía. Nhầm lẫn nhiều nhất về số lượng là positive đoán thành negative (91 câu) rồi negative đoán thành positive (52 câu).

- Ba trường hợp dự đoán sai trên dev: Các ca được chọn từ 10 câu sai đầu tiên theo thứ tự dev của mô hình chính thức (10 epoch), nên đây là một mẫu theo thứ tự chứ không phải mẫu ngẫu nhiên. Trong 10 câu đó, 7 câu liên quan đến neutral (5 câu bị đoán thành neutral, 2 câu có nhãn đúng là neutral) và 3 câu bị ngược nhãn (2 câu positive bị đoán negative, 1 câu negative bị đoán positive).

1. **neutral bị đoán thành negative**. Câu gốc có dạng "em không có bất cứ một lời phê bình nào". Câu minh họa: "em không có ý kiến nào khác về môn học này ." Câu chứa từ phủ định "không" cạnh một từ liên quan đến góp ý, những từ hay xuất hiện trong câu negative, trong khi nghĩa thật là không có nhận xét gì. Giả thuyết: mô hình dựa vào từ phủ định nhiều hơn ý của cả câu.
2. **positive bị đoán thành negative**. Câu gốc là một lời khen dài khoảng 87 token (tính cả dấu câu), giữa câu có mệnh đề "sinh viên không rõ vấn đề gì" và kết thúc bằng "em rất thích điều này". Câu minh họa: "thầy giảng rất kỹ , nếu em không hiểu chỗ nào thì thầy giải thích lại ngay , em rất thích cách dạy này ." Cực tính phủ định nằm trong mệnh đề điều kiện còn lời khen đứng sau. Giả thuyết: trạng thái ẩn cuối của LSTM khó giữ cả hai tín hiệu trong câu dài, và tín hiệu phủ định kéo kết quả sang negative.
3. **negative bị đoán thành positive**. Câu gốc "các bài thực hành cần bám sát theo chương trình lý thuyết" là lời góp ý, nhãn negative, nhưng không chứa từ tiêu cực nào. Câu minh họa: "các bài tập nên bám sát nội dung bài giảng ." Giả thuyết: phê bình ngầm dưới dạng đề nghị ("cần", "nên") không có từ khóa tiêu cực, còn cụm "bám sát chương trình" nghe như lời khen.

Ngoài ba ca trên, 5 trong 10 câu bị đoán thành neutral, trong đó có hai câu rất ngắn (4 và 5 token) là "cô rất nghiêm" (nhãn đúng negative) và "nói chuyện dễ nghe" (nhãn đúng positive). Câu ngắn ít tín hiệu nên mô hình thiên về lớp trung tính.

3. Bài 2: GRU 5 lớp và so sánh với LSTM

GRU đạt macro-F1 0.7767 trên test so với 0.7800 của LSTM; chênh 0.0033 quá nhỏ để nói mô hình nào tốt hơn, trong khi GRU ít hơn 21% tham số và nhanh hơn khoảng 9% mỗi epoch. Hai mô hình dùng cùng tập chia, từ điển, cách tách token, chỉ số sentiment và cấu hình của Bài 1; seed và mô hình được khởi tạo lại, optimizer không dùng lại.

Mô hình	Accuracy	Precision-macro	Recall-macro	F1-macro	F1 negative	F1 neutral	F1 positive

LSTM 5 lớp	0.9040	0.7883	0.7731	0.7800	0.9228	0.4889	0.9283
GRU 5 lớp	0.9024	0.7824	0.7719	0.7767	0.9163	0.4813	0.9326
TF-IDF + LR	0.8898	0.8103	0.6470	0.6483	0.9064	0.1196	0.9190

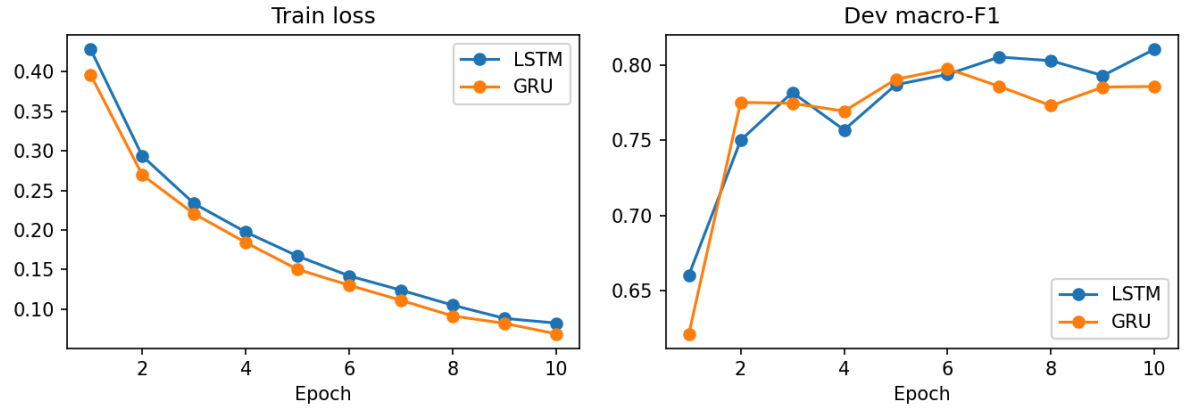
Chỉ số đo trên tập test, cùng định dạng với Bài 1. Cả hai mô hình hơn rõ TF-IDF ở macro-F1 và recall-macro, và cùng mức yếu ở neutral (0.4889 và 0.4813).

Mô hình	**F1-macro test**	**Tham số**	**Giây/epoch**	**Epoch tốt nhất (dev)**	**F1-macro dev tốt nhất**
LSTM	0.7800	3.138.007	5.3	10	0.8107
GRU	0.7767	2.468.823	4.8	6	0.7977

- Chất lượng: Chênh lệch giữa hai mô hình nằm trong dao động giữa các epoch liên tiếp của chính mỗi mô hình (F1 dev dao động tới khoảng 0.02 ở cả hai), và mỗi mô hình chỉ có một lần chạy với seed 42, nên báo cáo không kết luận GRU hay LSTM thắng. Về từng lớp, GRU thấp hơn ở negative (0.9163 so với 0.9228), cao hơn ở positive (0.9326 so với 0.9283) và gần như bằng ở neutral. Trên ma trận nhầm lẫn test, GRU đoán đúng 77 trong 167 câu neutral giống LSTM, nhưng nghiêng về negative nhiều hơn (53 câu so với 42) và ít sang positive hơn (37 câu so với 48).

- Chi phí: Phần embedding giống nhau (**460.500 tham số**) nên chênh lệch nằm ở RNN: 2.007.552 tham số của GRU so với 2.676.736 của LSTM (ít hơn 25%). GRU chỉ có ba nhóm trọng số mỗi lớp trong khi LSTM có bốn, nên mỗi bước tính ít phép nhân ma trận hơn; chỉ tốn **0.5 giây/ epoch**.

- Đồ thị: Loss train của GRU giảm nhanh hơn: 0.3964 ở epoch 1 và 0.0686 ở epoch 10, so với 0.4286 và 0.0822 của LSTM. Tuy nhiên F1 dev của GRU đạt đỉnh sớm ở epoch 6 (0.7977) rồi dao động trong khoảng 0.773 đến 0.786, trong khi LSTM vẫn tăng đến epoch 10.



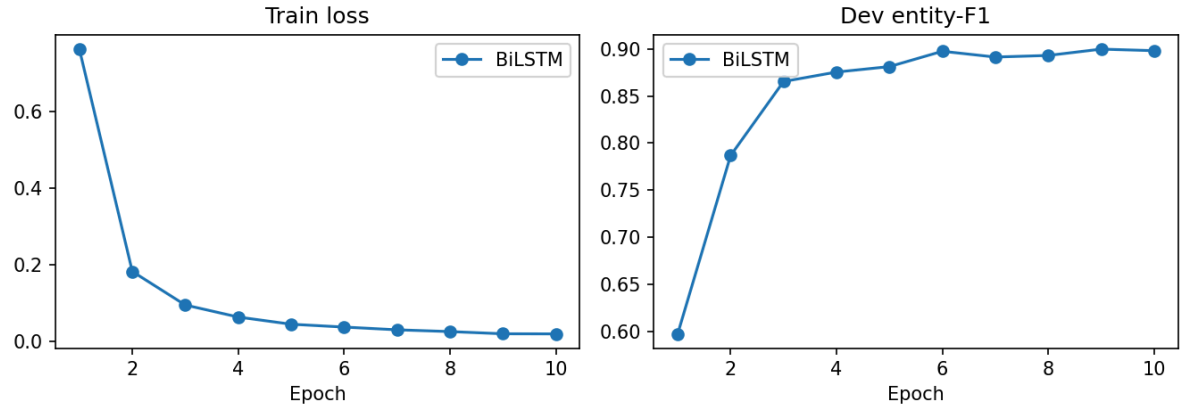
4. Bài 3: BiLSTM 5 lớp cho nhận diện thực thể (PhoNER_COVID19)

BiLSTM đạt micro-F1 mức thực thể 0.8909 trên test (precision 0.9003, recall 0.8816, seqeval strict IOB2); precision cao hơn recall nên mô hình bỏ sót thực thể nhiều hơn là dự đoán thừa.

Tập	Precision	Recall	Micro-F1
dev	0.9091	0.8909	0.8999
test	0.9003	0.8816	0.8909

- Chi phí huấn luyện: **8.305.297 tham số**: embedding 843.900 (10,2%), BiLSTM 5 lớp 7.450.624 (89,7%), lớp Linear(512, 21) 10. 773 (0,1%); trung bình **6.3 giây/epoch**; epoch tốt nhất theo dev là **epoch 9**.

- Đồ thị: Loss train giảm từ 0.7620 (epoch 1) xuống 0.0188 (epoch 10). Entity-F1 dev tăng nhanh từ 0.5971 lên 0.8655 sau 3 epoch, đạt 0.8976 ở epoch 6 rồi đi ngang trong khoảng 0.8915 đến 0.8999 (đỉnh ở epoch 9, epoch 10 là 0.8983). Loss vẫn giảm trong khi dev không tăng, tức mô hình khớp dữ liệu train hơn là học thêm đều cho tập dev.



F1 từng loại thực thể trên test (sắp theo F1 giảm dần):

Loại	Precision	Recall	F1	Số thực thể (support)
DATE	0.9529	0.9674	0.9601	1.654
PATIENT_ID	0.9223	0.9711	0.9461	2.005
GENDER	0.9312	0.9372	0.9342	462
AGE	0.9584	0.9107	0.9339	582
LOCATION	0.9141	0.9057	0.9099	4.441
TRANSPORTATION	0.8632	0.8497	0.8564	193
SYMPTOM_AND_DISEASE	0.8182	0.7368	0.7754	1.136
ORGANIZATION	0.8152	0.6978	0.7519	771

NAME	0.7509	0.6352	0.6882	318
JOB	0.5143	0.4162	0.4601	173

Năm loại có dạng bề mặt ổn định (ngày tháng, mã bệnh nhân, giới tính, tuổi, địa điểm) đều đạt F1 từ 0.91 đến 0.96. Ba loại yếu nhất là ORGANIZATION (0.7519), NAME (0.6882) và JOB (0.4601); cả bốn loại dưới 0.78 đều có recall thấp hơn precision rõ rệt (JOB 0.4162 so với 0.5143, NAME 0.6352 so với 0.7509),nghĩa là lỗi chủ yếu ở bỏ sót. JOB và NAME có ít thực thể nhất (173 và 318), nhưng SYMPTOM_AND_DISEASE có tới 1.136 thực thể mà F1 vẫn chỉ 0.7754, nên ít dữ liệu không phải lý do duy nhất.

- Phân tích lỗi: Ở chế độ strict, một thực thể sai biên tính là một thực thể bị bỏ sót cộng một thực thể dự đoán thừa (khi cụm dự đoán hợp lệ), còn chuỗi I- không có B- đứng trước không tạo ra thực thể nào, nên lỗi biên và lỗi loại đều làm giảm precision hoặc recall. Theo từng loại, recall thấp hơn precision ở JOB, NAME, ORGANIZATION và SYMPTOM_AND_DISEASE, tức là bỏ sót nhiều hơn dự đoán thừa. Các kiểu lỗi cụ thể được phân loại bên dưới từ 10 câu dev in ra. Giả thuyết (chưa kiểm chứng): tên riêng và nghề xuất hiện dưới 2 lần trong train bị đổi thành <unk>, làm mô hình mất thông tin để nhận ra chúng.

- Ba kiểu lỗi trên dev: phân loại thủ công 10 câu dev đầu tiên có lỗi của mô hình; trong 10 câu có 14 thực thể sai, nên đây là mẫu nhỏ theo thứ tự, không đại diện cho toàn bộ dev. Câu minh họa bên dưới là câu tự tạo mô phỏng kiểu lỗi, không phải câu gốc hay đầu ra thật.

1. **Bỏ sót hoàn toàn (dự đoán toàn O)**: 4 thực thể. "ngộ độc thuốc" và "Hệ miễn dịch suy yếu" (SYMPTOM_AND_DISEASE), "MGM" và "Công ty PouYuen" (ORGANIZATION). Minh họa: "Bệnh nhân bị suy hô hấp cấp , đang làm việc tại Công ty Minh Phát ." với cả hai cụm đều bị đoán O. Khớp với recall thấp của ORGANIZATION (0.6978) và SYMPTOM_AND_DISEASE (0.7368). Giả thuyết: tên riêng hiếm như MGM, PouYuen bị đổi thành <unk>.
2. **Sai biên, thẻ B-/I- không hợp lệ hoặc nhầm loại**: 6 thực thể. "tiệm pizza phố Trần Thái Tông" (mất phần đầu, chỉ còn "phố Trần Thái Tông"), "Nguyễn Quang Thuấn" (Quang bị gán I-JOB), "Bệnh viện Đà Nẵng" (Bệnh bị gán I-LOCATION thay vì B-LOCATION), "ngừng tim nhiều lần" (thiếu token cuối "lần"), "nhà máy Huệ Phong" (ORGANIZATION bị gán I-LOCATION) và "nhân viên tiệm bánh" (JOB bị gán I-SYMPTOM_AND_DISEASE ở hai token cuối). Minh họa: "Bệnh nhân sống ở phường Hòa Phát , quận Bình Thạnh ." với "phường" bị đoán I-LOCATION thay vì B-LOCATION. Ở chế độ strict, chuỗi I- không có B- đứng trước không tạo ra thực thể nào, nên cụm này vẫn tính là bỏ sót.
3. **Dự đoán thừa**: 4 thực thể. "nữ" bị gán B-GENDER trong hai câu mà nhãn đúng là O; "tiếp viên hàng không" bị gán JOB; "cá" bị gán B-LOCATION. Minh họa: "Cô ấy mua rau và cá ở chợ Bình Điền ." với "cá" bị đoán B-LOCATION. Với "nữ" và "tiếp viên hàng không", dự đoán của mô hình có vẻ hợp lý về nghĩa, nên có thể nhãn gốc không nhất quán giữa các câu.

Trong mẫu này, lỗi sai biên hoặc nhầm loại (6) nhiều hơn bỏ sót hoàn toàn (4) và dự đoán thừa (4). Với 10 câu, chưa đủ cơ sở để kết luận kiểu nào chiếm ưu thế trên toàn bộ dev; muốn vậy cần đếm trên toàn bộ dev.

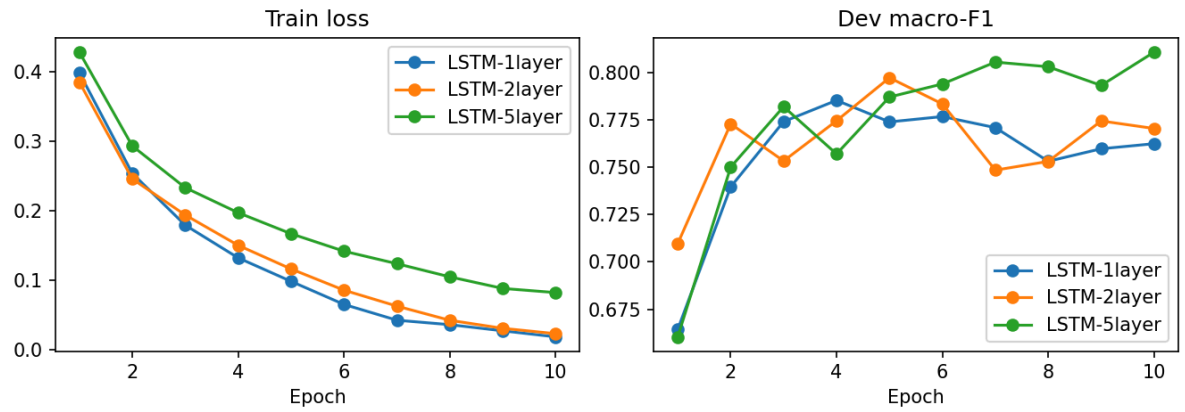
5. Bài 4a: Ảnh hưởng của độ sâu (LSTM 1, 2 và 5 lớp)

Mô hình **5 lớp** cho macro-F1 test cao nhất (0.7800 so với 0.7471 ở 1 lớp và 0.7433 ở 2 lớp), nhưng accuracy cả ba gần như bằng nhau (0.8989 đến 0.9040) và phần hơn nằm ở lớp neutral, với chỉ một seed. Chỉ độ sâu thay đổi, hidden 256, embedding 300 và các siêu tham số khác giữ nguyên; mô hình 5 lớp chính là lần chạy của Bài 1.

Số lớp	Tham số (RNN)	Giây/epoch	Epoch tốt nhất	F1-macro dev tốt nhất	F1-macro test	Accuracy test	F1 neutral test
1	1.032.663 (571.392)	2.1	4	0.7853	0.7471	0.8999	0.391
2	1.558.999 (1.097.728)	2.9	5	0.7972	0.7433	0.8989	0.384
5	3.138.007 (2.676.736)	5.1	10	0.8107	0.7800	0.9040	0.489

F1 của hai lớp lớn gần như không đổi theo độ sâu: negative 0.922, 0.920, 0.923 và positive 0.929, 0.925, 0.928 (lần lượt 1, 2, 5 lớp). Toàn bộ chênh lệch macro-F1 đến từ neutral, lớp chỉ có 167 mẫu test, nên chênh vài chục câu dự đoán đúng hay sai là đủ làm F1 của lớp này đổi đáng kể.

- Đồ thị: Mô hình nông khớp train rất nhanh: loss của 1 lớp xuống 0.0184 và của 2 lớp xuống 0.0230 ở epoch 10, trong khi F1 dev đạt đỉnh sớm (epoch 4 với 0.7853 và epoch 5 với 0.7972) rồi giảm, về 0.7624 ở 1 lớp và 0.7704 ở 2 lớp. Mô hình 5 lớp học chậm hơn (loss 0.0822 ở epoch 10), F1 dev vẫn đang lên đến epoch 10 với 0.8107, nên giới hạn 10 epoch có thể đang cắt ngang đường học của nó và chưa biết nó sẽ bão hòa ở đâu. F1 dev của cả ba dao động giữa các epoch (mô hình 2 lớp tụt từ 0.7972 ở epoch 5 xuống 0.7484 ở epoch 7), cỡ bằng chênh lệch giữa các mô hình.



Tách độ sâu và số tham số. Thiết kế này không tách được hai yếu tố. Embedding giữ cố định 460.500 tham số, còn phần RNN tăng 4,7 lần (571.392 lên 2.676.736) khi đi từ 1 lên 5 lớp, nên mô hình sâu hơn cũng lớn hơn. Ngoài ra dropout giữa các lớp RNN chỉ có khi số lớp lớn hơn 1 (theo cách PyTorch cài đặt), nên mô hình 1 lớp chỉ có dropout trước lớp tuyến tính cuối. Chênh lệch kết quả vì vậy là tác động gộp của độ sâu, kích thước mô hình và dropout; muốn tách riêng độ sâu cần thêm một mô hình nông có số tham số tương đương (không nằm trong yêu cầu của đề).

- Chi phí Thời gian mỗi epoch tăng theo số lớp (2.1, 2.9, 5.1 giây); mô hình 5 lớp chậm hơn khoảng 2,4 lần mô hình 1 lớp.

Kết luận: Ở seed 42 và giới hạn 10 epoch, mô hình 5 lớp tốt nhất theo cả F1 dev và F1 test.

6. Kết luận và hạn chế

Mạng hồi quy 5 lớp vượt baseline TF-IDF ở bài phân loại và BiLSTM đạt micro-F1 0.8909 ở bài NER, nhưng các mô hình phân loại chỉ khác nhau rõ ở lớp neutral, còn hai lớp lớn gần như bằng nhau.

Kết luận từng bài

- Bài 1: LSTM 5 lớp đạt macro-F1 test 0.7800, hơn TF-IDF (0.6483) chủ yếu nhờ neutral (0.489 so với 0.120); accuracy chỉ hơn 0.014.
- Bài 2: GRU (0.7767) tương đương LSTM (0.7800) về chất lượng, với ít hơn 21% tham số và nhanh hơn khoảng 9% mỗi epoch.
- Bài 3: micro-F1 thực thể 0.8909; JOB (0.4601), NAME (0.6882) và ORGANIZATION (0.7519) yếu nhất, chủ yếu vì bỏ sót (recall thấp hơn precision).
- Bài 4a: ở seed 42, 5 lớp tốt hơn 1 và 2 lớp (macro-F1 test 0.7800 so với 0.7471 và 0.7433), nhưng chưa đủ để kết luận độ sâu nói chung có lợi.